Uczenie maszynowe

Paweł Rychlikowski

Instytut Informatyki UWr

30 kwietnia 2021

Uczenie ze wzmocnieniem

- Zakładamy, że nie dysponujemy modelem (czyli przejściami, prawdpodobieństwami i nagrodami)
- Możemy wszakże wykonywać pewne eksperymenty w naszym systemie, w wyniku których zdobywamy wiedzę jak nam poszło

Uwaga

Zauważmy, że to pasuje do naszych samochodzików z rozmytymi stanami (eksperyment przeprowadzamy na prawdziwym modelu, ale obserwujemy model „rozmyty")

Ogólny schemat uczenia ze wzmocnieniem

Dla $t \in 1, 2, 3, \ldots$

- Wybieramy akcje $a_t = \pi_{act}(s_{t-1})$ (**jak?**)
- Wykonujemy akcję i obserwujemy nowy stan s_t
- Uaktualniamy parametry (**jak?**)

Metody Monte Carlo

- Estymujemy model podczas eksperymentów
- Rozwiązujemy wyszacowane MDP.

Szacowany MDP

- $\hat{T}(s, a, s') = \frac{\text{cnt}(s,a,s')}{\text{cnt}(s,a)}$
- Nagroda: średnie **r** dla zaobserwowanych **s a r s'**

Eksploracja i eksploatacja

- Jaką polityką mamy badać świat?
  a) Wybierającą akcje losowo (strata czasu?)
  b) Wybierającą akcje prowadzącą do stanu o najlepszej wartości V (ale możemy się zafiksować na nieoptymalnej ścieżce)
- Wybór między a) i b) to wybór między eksploracją i eksploatacją
  - Pamiętamy: strategia ε-zachłanna.

Możemy przeplatać etapy wyznaczania modelu i rozwiązywania MDP (bo w kolejnych iteracjach mamy możliwość wykorzystania lepszej strategii eksploatacyjnej).

Pytanie kontrolne

Dlaczego przeplatanie estymacji modelu i wyznaczania optymalnej polityki może nam pomóc osiągnąć lepszy rezultat?

Bezmodelowe uczenie ze wzmocnieniem

Mówiliśmy o metodach Monte Carlo, w których przeprowadzamy eksperymenty (losowe przebiegi), żeby estymować (nieznane) parametry MDP.

- Nowy cel: od razu liczyć $Q(s, a)$, nie przejmując się tworzeniem modelu.
- Zaczniemy od obliczenia $Q_\pi(s, a)$

Bezmodelowe Monte Carlo

Definicja (przypomnienie)

$Q_\pi(s, a)$ to oczekiwana sumaryczna nagroda, jaką otrzymamy wykonując w stanie s akcję a, a następnie postępując zgodnie z polityką π

- Użyteczność (dla konkretnego przebiegu): $u_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots$
- $\hat{Q}_\pi(s, a) =$ średnie u_t, gdzie $s_{t-1} = s$, $a_t = a$

Bezmodelowe Monte Carlo – inne sformułowanie

- Zamiast liczyć średnią z całości, można myśleć o uaktualnianiu średniej wraz z pojawieniem się kolejnej informacji.
- Niech: $\eta = \frac{1}{1+\text{cnt}(s,a)}$
- $\hat{Q}_\pi(s,a) \leftarrow (1-\eta)\hat{Q}_\pi(s,a) + \eta u$ (gdzie u jest użytecznością zaobserwowaną w konkretnym przebiegu)

Sprawdźmy, czy to się zgadza.

$$\frac{\text{cnt}(s,a)\hat{Q}_\pi(s,a)}{1+\text{cnt}(s,a)} + \frac{u}{1+\text{cnt}(s,a)}$$

Bezmodelowe Monte Carlo – inne sformułowanie (2)

$$\hat{Q}_\pi(s,a) \leftarrow (1-\eta)\hat{Q}_\pi(s,a) + \eta u$$

- u jest zaobserwowaną użytecznością
- $\hat{Q}_\pi(s,a)$ jest naszą predykcją.

Reguła ta minimalizuje odległość między predykcją a obserwacją.

Bootstraping

Uwaga

W informatyce często, rozwiązując jakieś zadanie, korzystamy z niedoskonałego (tymczasowego) rozwiązania, żeby rozwiązać zadanie lepiej.

Przykład

Szukanie dobrych i złych słów (analizujemy wpisy na jakimś forum), na początku znamy kilka przykładowych dobrych i złych słów.

Będziemy używać Q (poprzedniej wartości) do obliczenia nowego Q

Bootstraping: SARSA

Obserwujemy ciąg akcji i nagród:

$$s_0, a_1, r_1, s_1, a_2, r_2, s_2, \ldots$$

- Uaktualnianie Monte Carlo:

$$\hat{Q}_\pi(s,a) \leftarrow (1-\eta)\hat{Q}_\pi(s,a) + \eta u$$

- SARSA (obserwujemy s, a, r, s', a'):

$$\hat{Q}_\pi(s,a) \leftarrow (1-\eta)\hat{Q}_\pi(s,a) + \eta(r + \gamma\hat{Q}_\pi(s',a'))$$

W algorytmie SARSA zamiast konkretnego (zaobserwowanego) u bierzemy zaobserwowaną jego i pierwszą część (r) i estymowaną resztę (zielony jest cel)

Uwaga

Nie musimy czekać do końca epizodu, żeby uaktualnić wartość Q!

Value iteration vs. SARSA

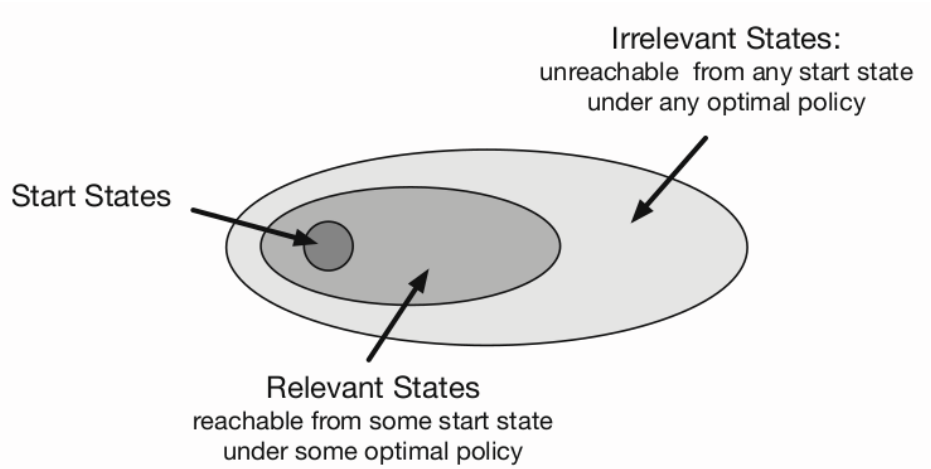

źródło: Sutton, Reinforcement Larning. An introduction

- VI liczy wartości dla stanów „nieoptymalnych”
- VI liczy wartości dla stanów nieosiągalnych (łatwo wymyślić dla autek taką kombinację prędkości i położenia, która jest bezużyteczna)

W momencie, gdy operujemy przebiegami, być może sensownymi, to koncentrujemy się na estymacji rzeczy użytecznych (a na pewno na osiągalnych!)

Q-learning

Uwaga

SARSA estymuje $Q_\pi(s, a)$. Najbardziej naturalnym celem jest znajomość Q_{opt}.

- Algorytm umożliwiający bezpośrednie obliczanie Q_{opt} to właśnie **Q-learning**.
- Również radzimy sobie bez modelu.

Q-learning

Standardowy kształt reguły:

$$Q(s,a)_{\text{opt}} \leftarrow (1-\eta)Q(s,a)_{\text{opt}} + \eta \text{ cel}$$

Celem jest $r + \gamma V_{\text{opt}}(s')$
Natomiast:

$$V_{\text{opt}}(s') = \max_{a' \in \text{Actions(s')}} Q_{\text{opt}}(s', a'))$$

Algorytm **Q-learning**

Dla zaobserwowanych s, a, r, s' (dla czytelności bez opt):

$$Q(s,a) \leftarrow (1-\eta)Q(s,a) + \eta(r + \gamma \max_{a' \in \text{Actions(s')}} Q(s', a')))$$

O wadze eksploracji

- Jeżeli chcemy zachowywać się optymalnie powinniśmy wiedzieć coś o każdej parze (s,a)
- Istnieją dwie możliwości:
  1. Rzeczywiście mamy szansę (w granicy) wygenerować przebieg z każdą parą (s,a)
  2. Umiemy jakoś generalizować i wywnioskować coś na temat (s,a) korzystając z podobnego (s', a')

Koniec części II

Uczenie maszynowe

Obok wnioskowania i przeszukiwania jeden z głównych silników sztucznej inteligencji.

Użyteczne między innymi w sytuacjach o których ostatnio mówiliśmy, gdy nie chcemy pamiętać wartości $Q(s, a)$ lecz umieć ją obliczyć

Uczenie z nadzorem

Fragment oceny opisowej ze świadectwa dziecka

... umie odróżniać psa od kota.

Dane uczace

Uczenie z nadzorem

Fragment oceny opisowej ze świadectwa dziecka

... umie odróżniać psa od kota.

Dane uczace i dane testowe

Uczenie się

- Spróbujemy usystematyzować nasze intuicje związane z uczeniem.
- Co wiemy:
  a. Mamy przykłady, próbujemy je uogólnić.
  b. Jedno z podstawowych zadań: klasyfikacja, czyli przypisanie przypadkowi jego klasy.
  c. Przykłady:
     - Ocena, czy mail należy do spam czy też nie-spam.
     - Wybór rasy dla zdjęcia psa
     - Czy napis jest adresem e-mail, url-em, nazwą firmy, imieniem i nazwiskiem, czymś innym?

Regresja

- Oczekiwanym wynikiem może być liczba rzeczywista.
- Przykłady:
  - predycja ceny nieruchomości,
  - ocena masy ciała (gdy znamy płeć i wzrost),
  - przewidywanie zużycia wody (dla MPWiK), gdy znamy temperaturę i dzień tygodnia

Cechy kota i psa

Uwaga

Zadanie rozróżnienia kota i psa byłoby łatwiejsze, gdybyśmy mieli dane nie obrazki, lecz cechy zwierzęcia

Przykłady?

- masa ciała,
- odległość między oczami,
- odległość nosa i oka,
- długość włosów,
- długość wąsów,
- długość ogona

użyteczne mogłyby być też na przykład proporcje różnych cech i inne wtórne cechy (wyliczone z podstawowych)

Cechy (wektor cech)

- Abstrakcyjny obiekt możemy zamienić na wektor cech.
- Dla (zabawkowego) klasyfikatora **czy-email?**, możemy mieć:
  - Czy długość większa od 10?
  - Jaki procent znaków to znaki alfanumeryczne?
  - Czy zawiera @?
  - Czy kończy się na .com (i tak dalej)

Cechami mogą być też na przykład wartości składowych pikseli, kolejne wartości pliku wave, zbiory pomiarów wszystkich wodomierzy z ostatniej doby, itd.

Dla obiektu x wektor cech oznaczamy często jako $(\phi_1(x), \ldots, \phi_n(x))$.

Dane i uczenie

- Dane uczące – zbiór przykładów, często w postaci:

  (wektor-cech1, wynik1)
  (wektor-cech2, wynik2)
  (wektor-cech3, wynik3)
  ...

Podział dostępnych danych

Definicja 1

Zbiór **uczący** jest podstawowym zbiorem, który będziemy wykorzystywać do zdobywania wiedzy o problemie.

Definicja 2

Zbioru **walidacyjnego** używamy do wyboru rodzaju algorytmu lub do wyboru hiperparametrów algorytmu.

Definicja 3

Zbiór **testowy** używany jest **tylko** do ostatecznego testu, który ma nas przekonać, jak dobrze uogólnia rzeczywistość nasz mechanizm.

Do zbioru testowego nawet nie zaglądamy, nie analizujemy błędów, itd!

Czas na przerwę

Klasyczne zadanie klasyfikacji obrazów

MNIST jest zbiorem około 60K czarnobiałych obrazków 28×28 zawierających ręcznie pisane cyfry.

Jest on powszechnie używany do testowania różnych algorytmów uczenia (głównie klasyfikacji, ale nie tylko)

MNIST – przedstawienie danych

MNIST – wyszukiwanie wzorców

- Naturalnym rozwiązaniem jest stworzenie wzorca (lub wzorców) dla każdej cyfry.
- Jak to zrobić?

Dwa warianty

1. Jeden wzorzec dla wszystkich obrazków danej cyfry.
2. Wiele wzorców (nawet: każda cyfra wzorcem)

Jeden wzorzec dla cyfry

- Naturalnym wzorcem może być średnia wszystkich egzemplarzy danej cyfry
- Przy klasyfikacji obrazka **o** wybieramy wzorzec **w** najbardziej podobny do **o**
- Co to znaczy podobny?
  - Wysoki iloczyn skalarny?
  - *Wysoki iloczyn skalarny znormalizowanych wektorów?*
  - Niewielka odległość euklidesowa (a może jakaś inna)?

Wyniki eksperymentu

Poprawność klasyfikacji to około **82.1%** (dla iloczynów skalarnych znormalizowanych wektorów)

Wyniki klasyfikacji z „wzorcami średnimi”

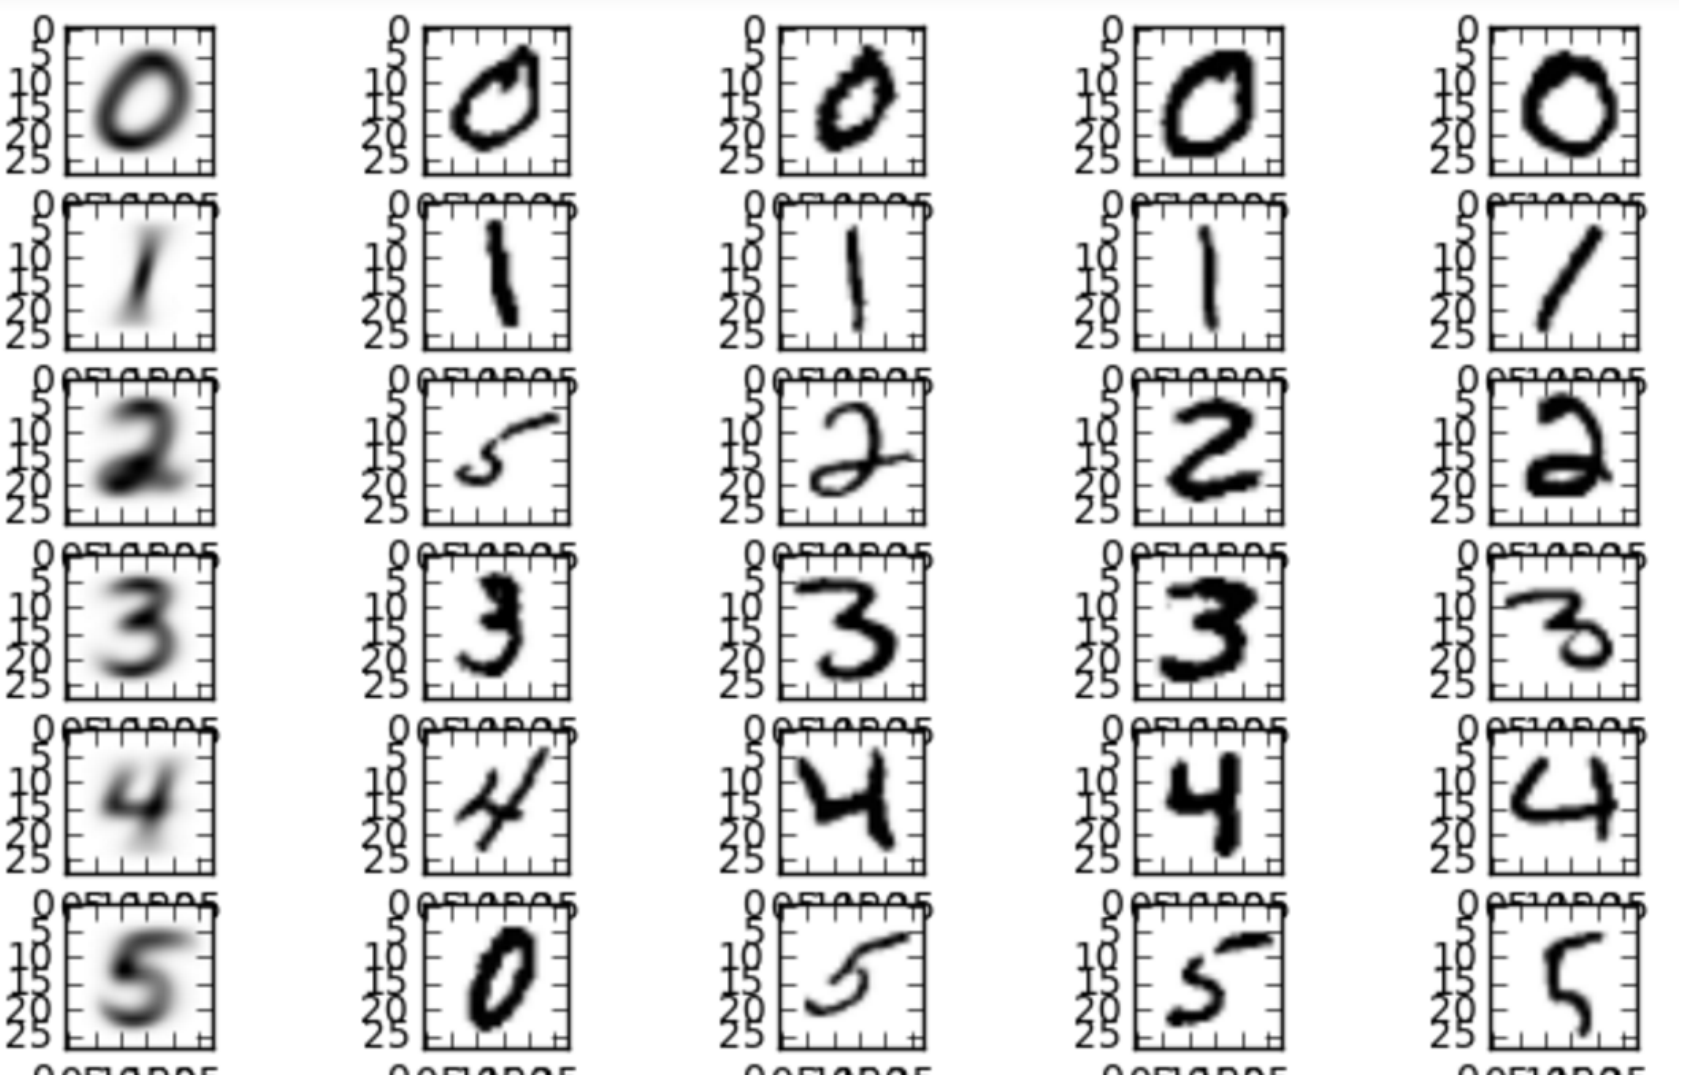

Wyniki klasyfikacji z „wzorcami średnimi”

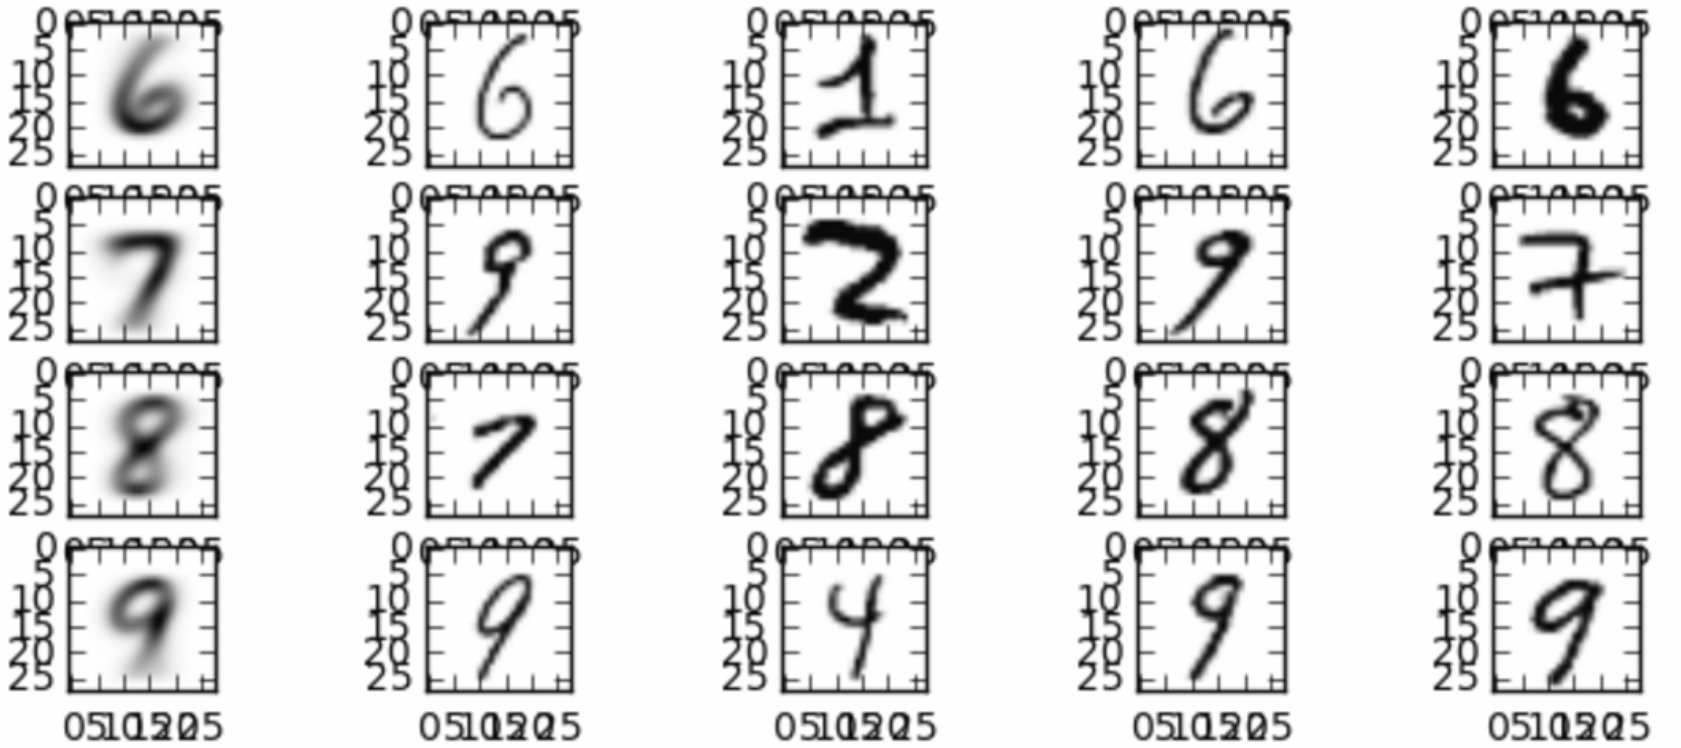

K najbliższych sąsiadów. KNN

- Pamiętamy wszystkie wektory ze zbioru uczącego.
- Klasyfikując obrazek znajdujemy K najbliższych sąsiadów i pozwalamy im głosować

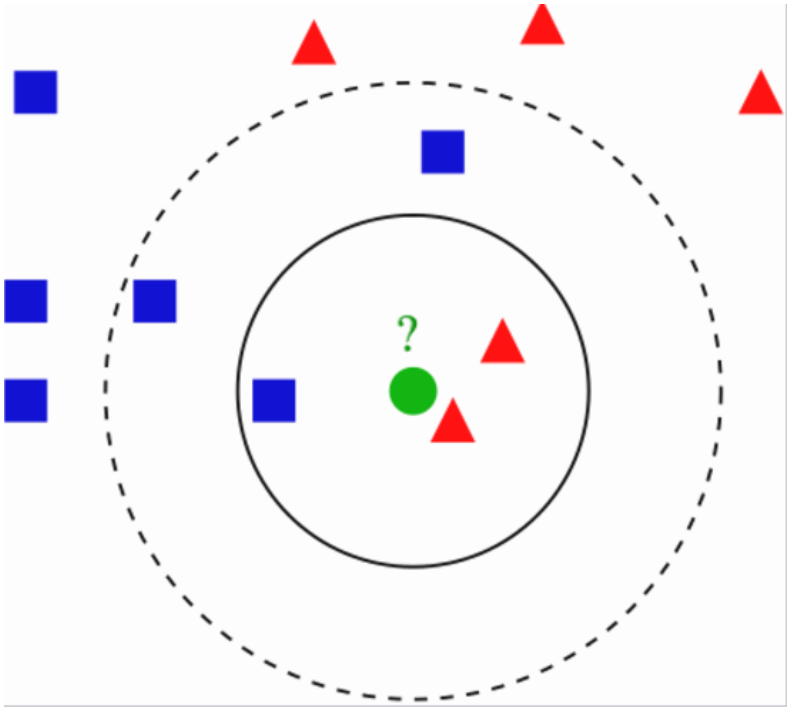

MNIST i KNN

- Podobnieństwo mierzymy iloczynem skalarnym znormalizowanych wektorów (czyli cosinusem)
- Testujemy na próbce (bo inaczej trwa bardzo długo)
- $K = 3$
- Wyniki:
  - Zbiór uczący: **98.55%**
  - Zbiór testowy: około **97%**

MNIST i KNN. Przykładowe błędy

Z tymi cyframi mieliśmy problemy (zaznaczona prawidłowa klasyfikacja)

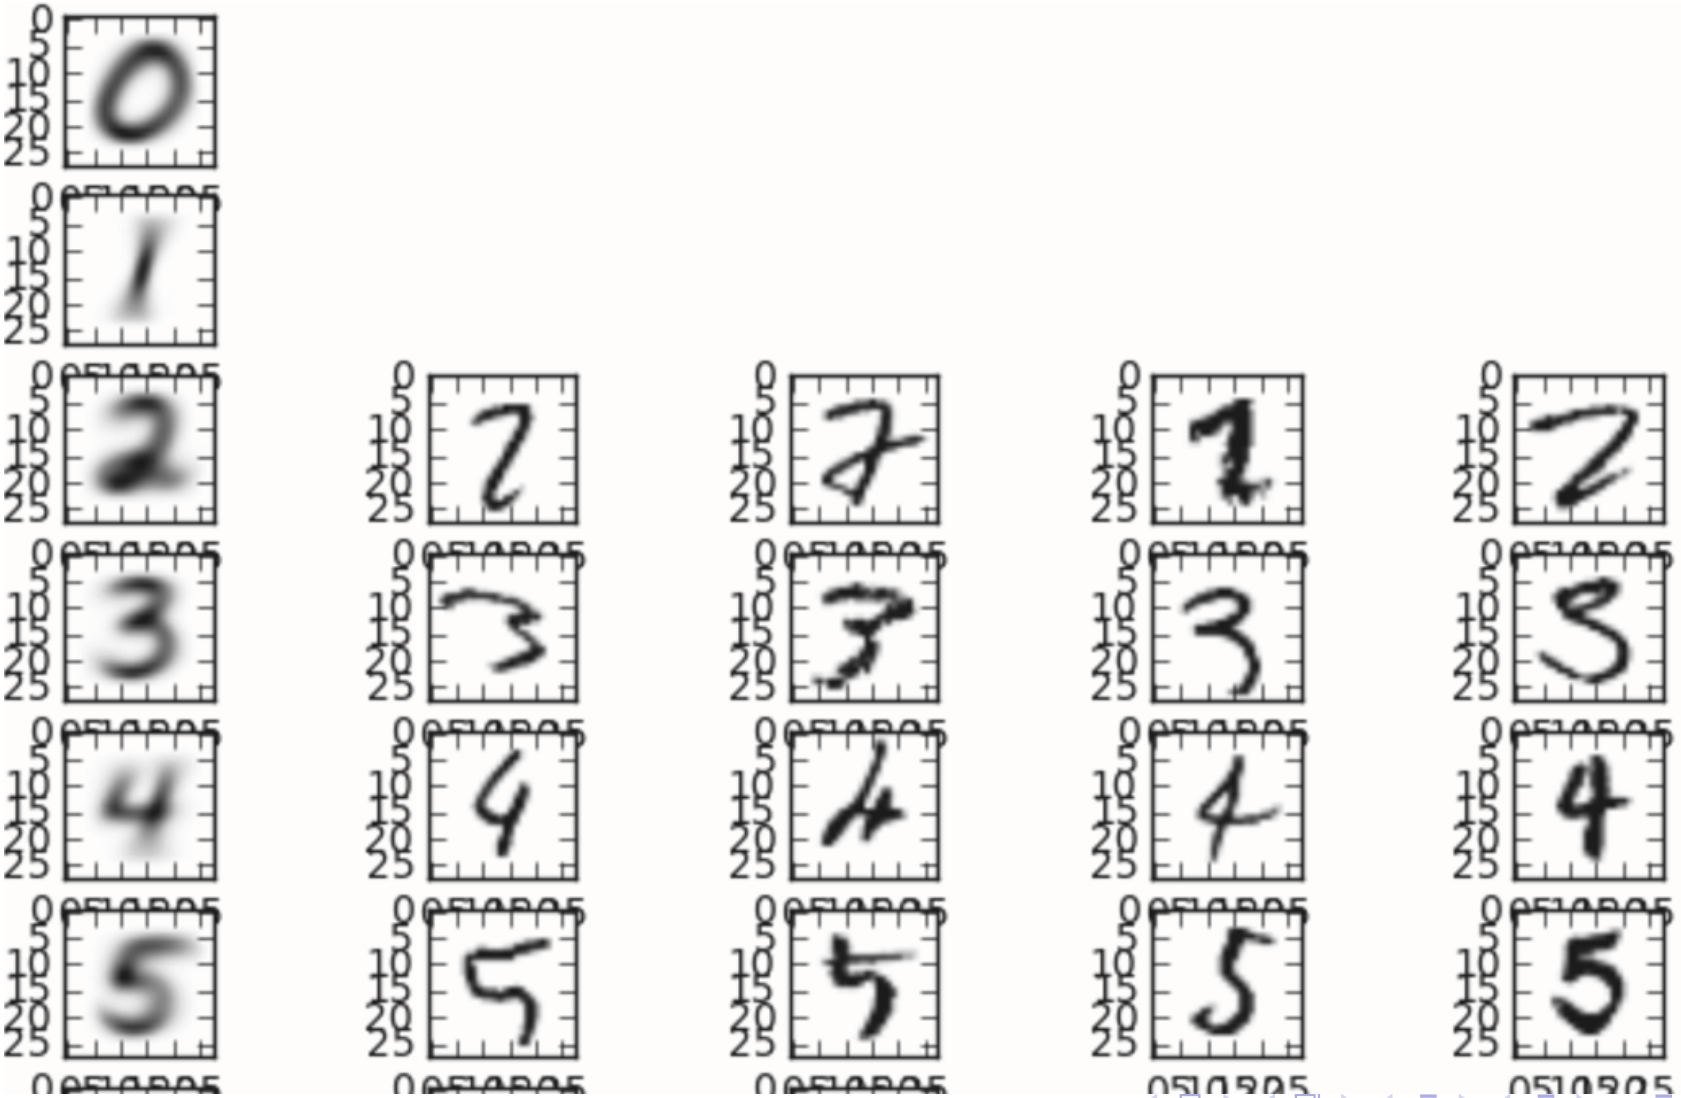

MNIST i KNN. Przykładowe błędy

Z tymi cyframi mieliśmy problemy (zaznaczona prawidłowa klasyfikacja)